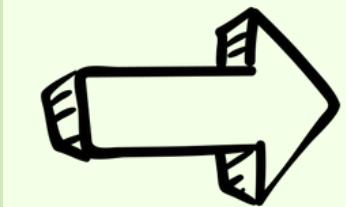


# Pflanzenkrankheiten erkennen mit CNNs

eine Präsentation von  
**Emily Krüger & Thien Vu David Nguyen**

# MOTIVATION & PROBLEM

- Pflanzenkrankheiten ->  
Ernteverluste und  
Pflanzenschäden
- Visuelle Diagnose oft  
schwierig
- Viele Krankheiten sehen  
ähnlich aus

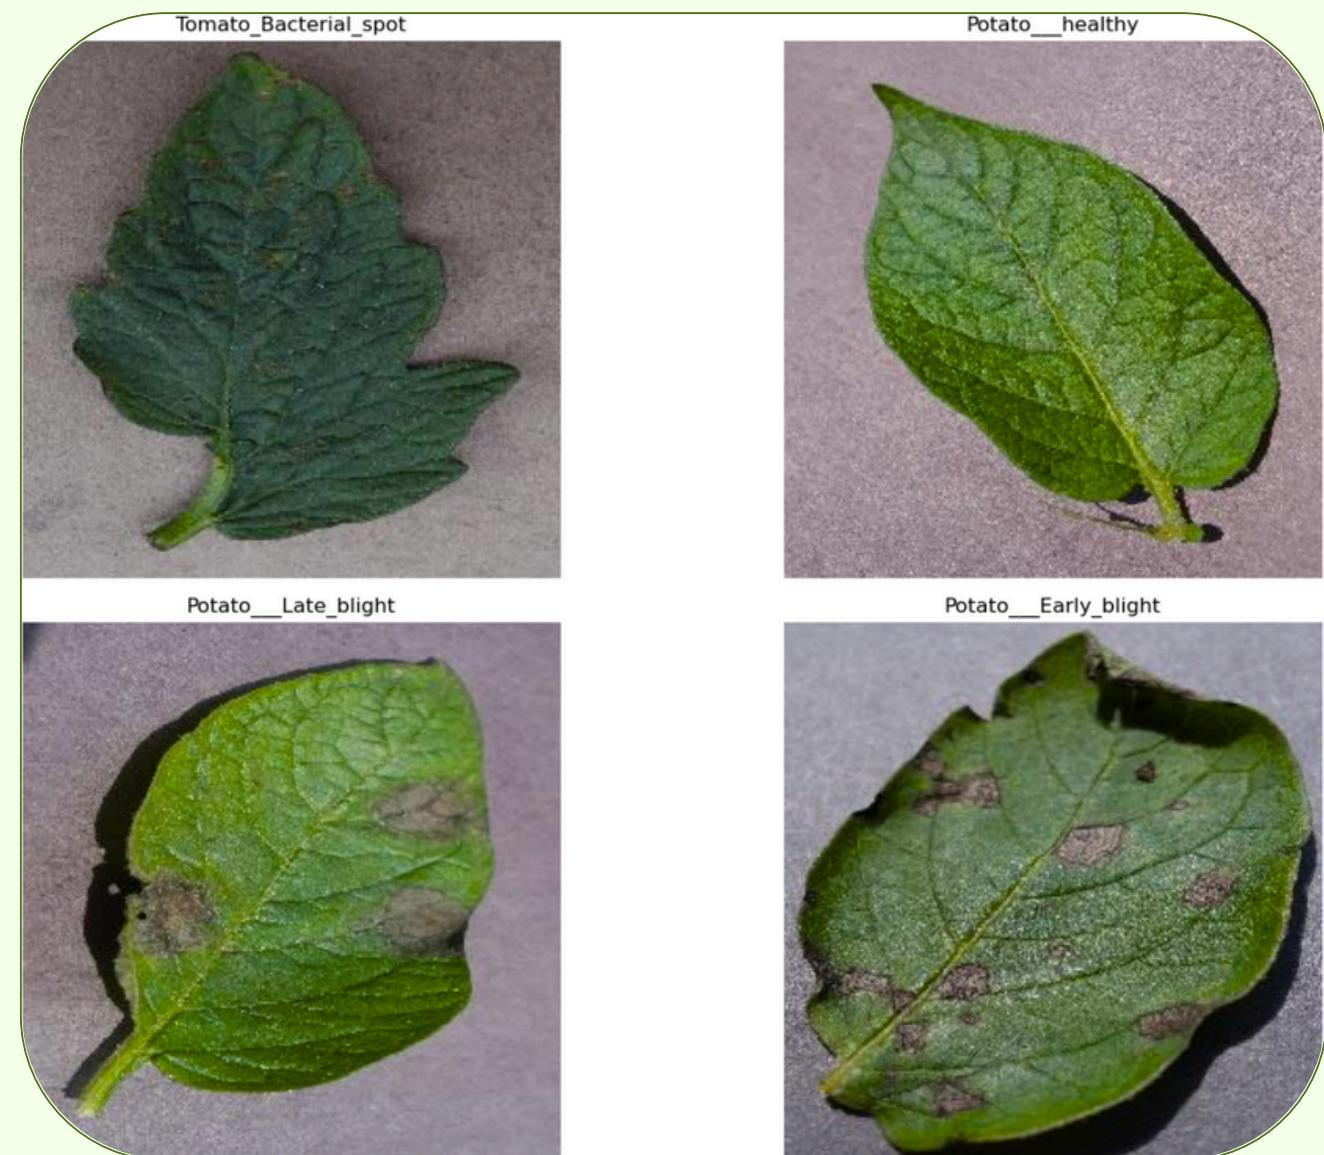


Erstellung von CNN, welches  
anhand von Pflanzenblättern  
erkennen soll, ob Pflanze  
gesund oder erkrankt ist.

# DATENSATZ: PLANTVILLAGE

## Inhalt:

- > 20.000 Bilder
- 15 Klassen
- Quelle: Kaggle / PlantVillage



# DATENSATZ: CHANCEN & RISIKEN

## Vorteile

- viele Bilder
- hohe Qualität
- klare Klassen

## Nachteile

- unbalancierte Klassen
- sehr ähnliche Krankheiten
- keine Outdoor-Szenarien

# TRAIN/VAL/TEST SPLIT

- Split: 70% Train/ 15% Validation/ 15% Test
- stratifiziert nach Label → Klassenverteilung bleibt in allen Splits ähnlich

Größe der Datensplits:

Training: 14446  
Validation: 3096  
Test: 3096

Anzahl Klassen:

Train: 15  
Val: 15  
Test: 15

Klassenreihenfolge:

```
0 Pepper_bell_Bacterial_spot
1 Pepper_bell_healthy
2 Potato_Early_blight
3 Potato_Late_blight
4 Potato_healthy
5 Tomato_Bacterial_spot
6 Tomato_Early_blight
7 Tomato_Late_blight
8 Tomato_Leaf_Mold
9 Tomato_Septoria_leaf_spot
10 Tomato_Spider_mites_Two_spotted_spider_mite
11 Tomato_Target_Spot
12 Tomato_Tomato_YellowLeaf_Curl_Virus
13 Tomato_Tomato_mosaic_virus
14 Tomato_healthy
```

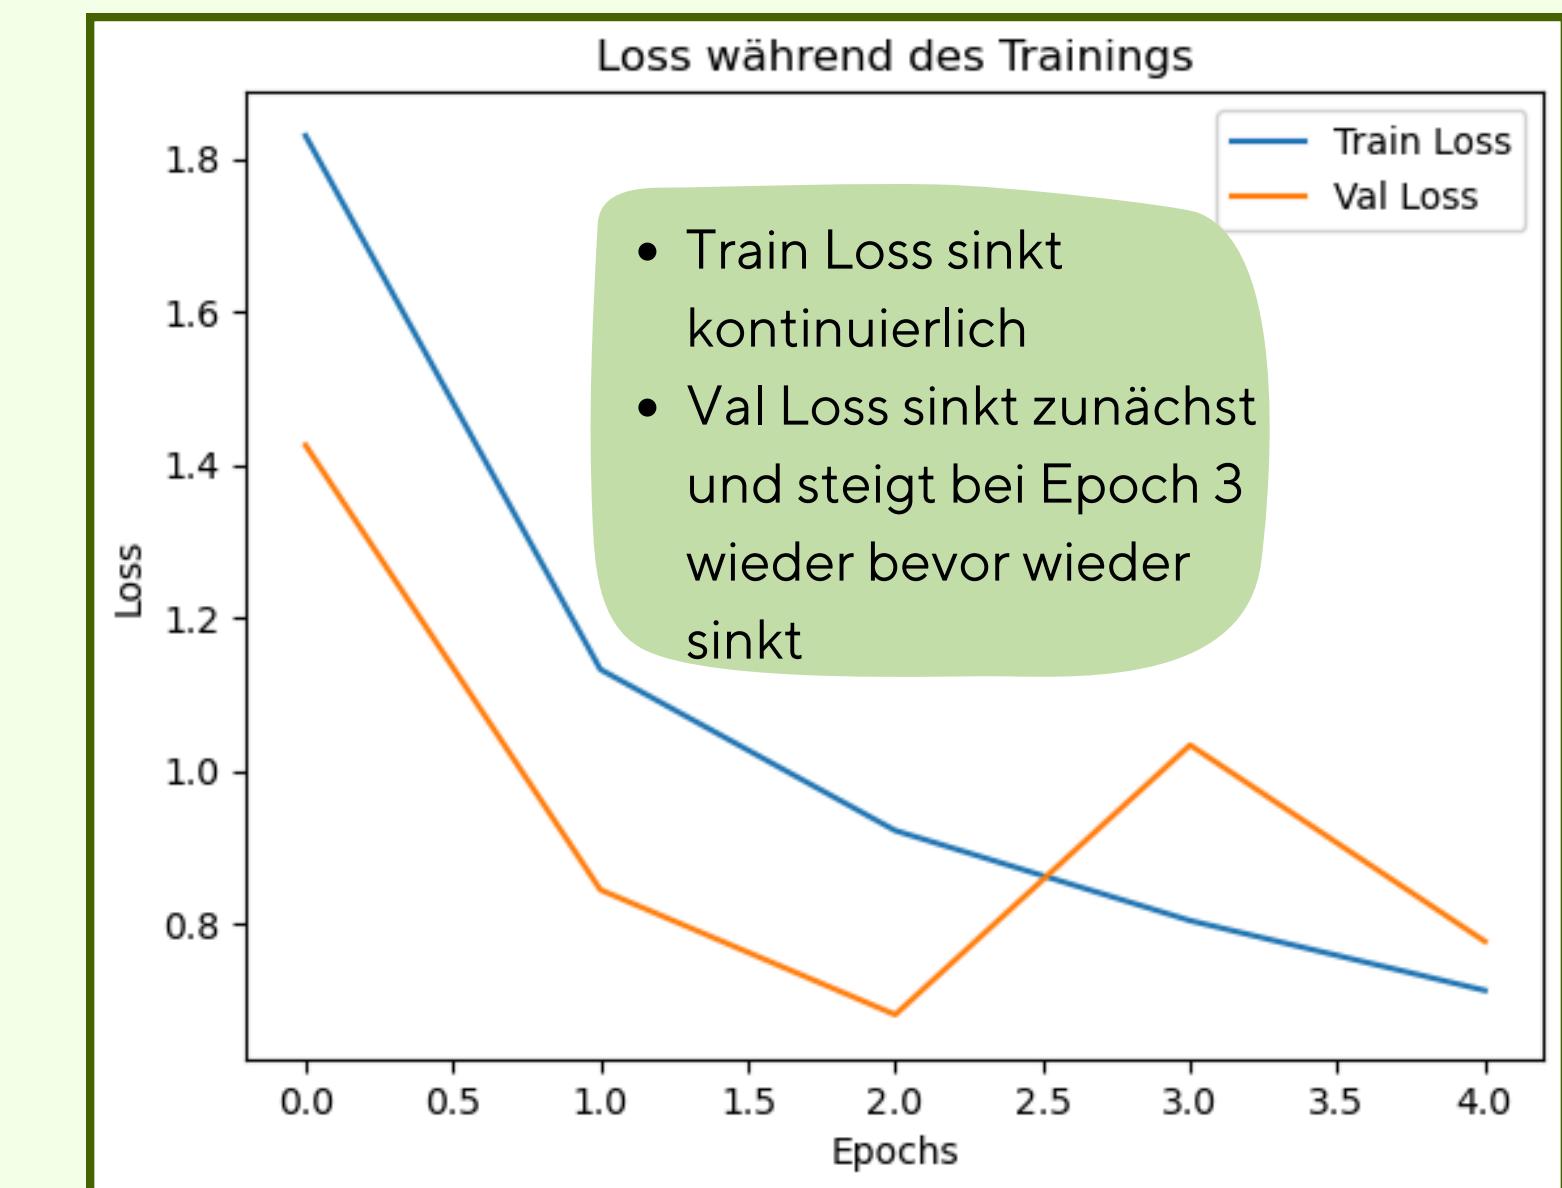
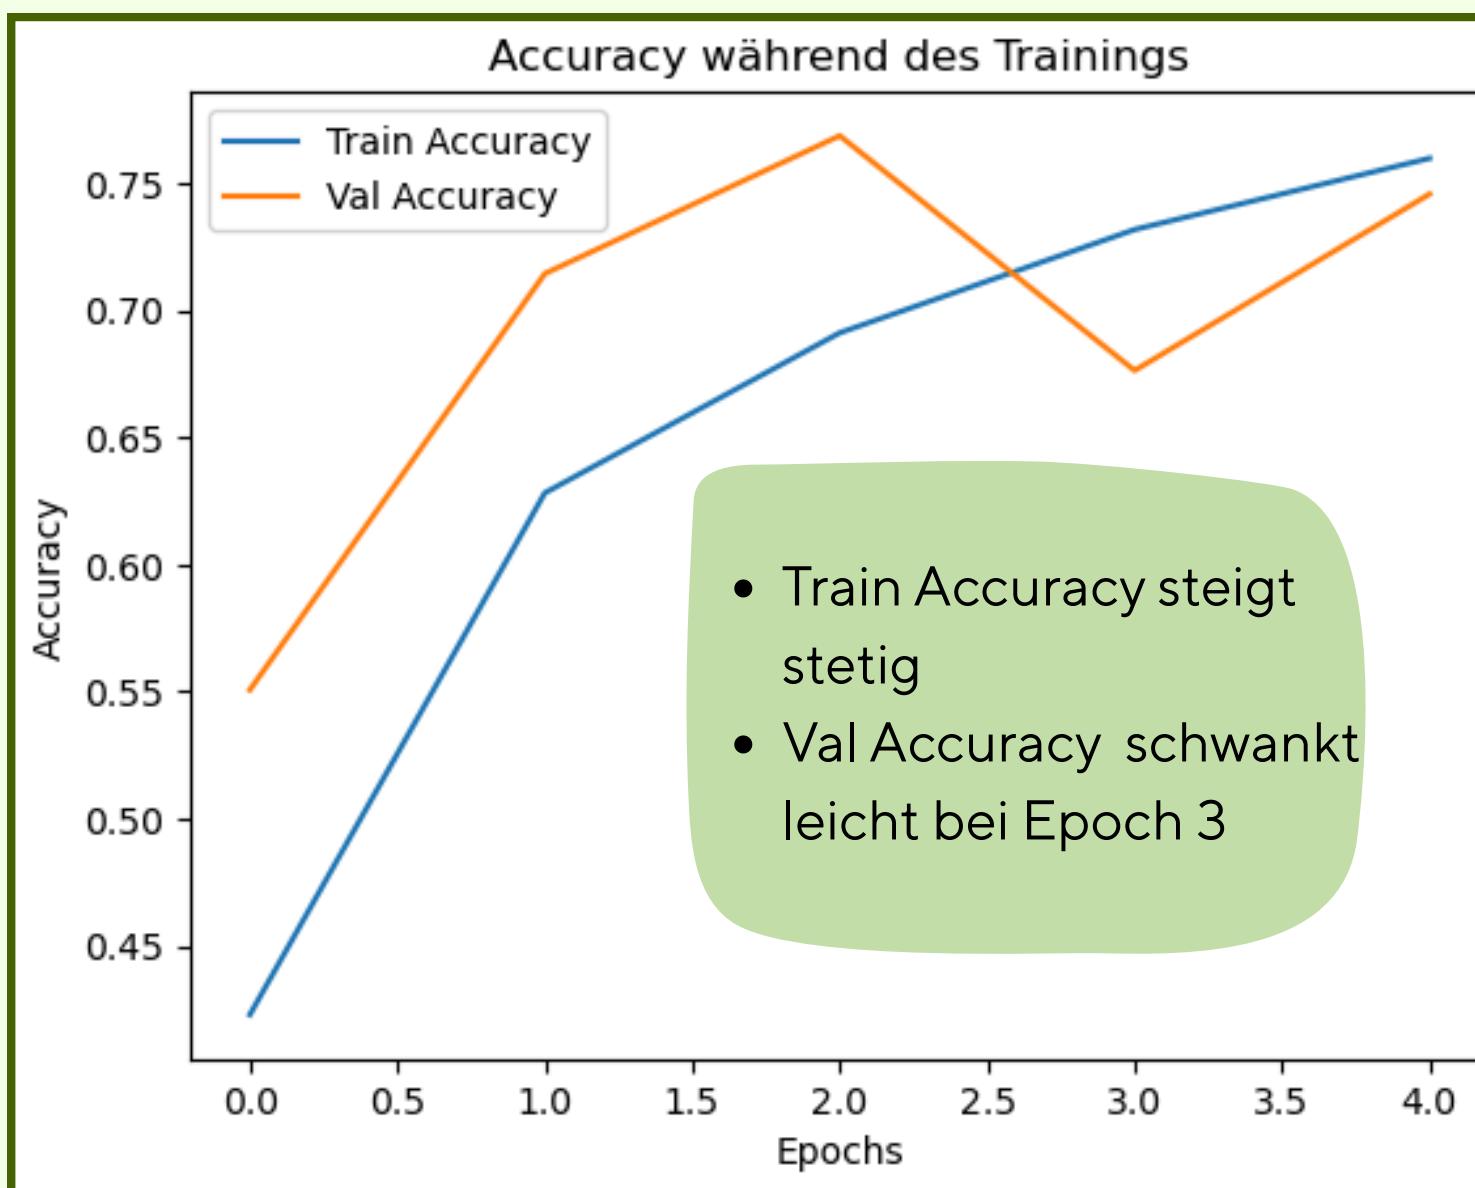
# CNN

## Training:

- Optimizer: Adam
- Loss: Categorical Crossentropy
- Early-Stopping auf Validation-Loss

```
Epoch 1/5
452/452 122s 265ms/step - accuracy: 0.4230 - loss: 1.8298 - val_accuracy: 0.5507 - val_loss: 1.4252
Epoch 2/5
452/452 127s 281ms/step - accuracy: 0.6282 - loss: 1.1321 - val_accuracy: 0.7145 - val_loss: 0.8439
Epoch 3/5
452/452 123s 272ms/step - accuracy: 0.6912 - loss: 0.9214 - val_accuracy: 0.7687 - val_loss: 0.6807
Epoch 4/5
452/452 127s 281ms/step - accuracy: 0.7318 - loss: 0.8037 - val_accuracy: 0.6764 - val_loss: 1.0333
Epoch 5/5
452/452 128s 284ms/step - accuracy: 0.7599 - loss: 0.7124 - val_accuracy: 0.7458 - val_loss: 0.7764
```

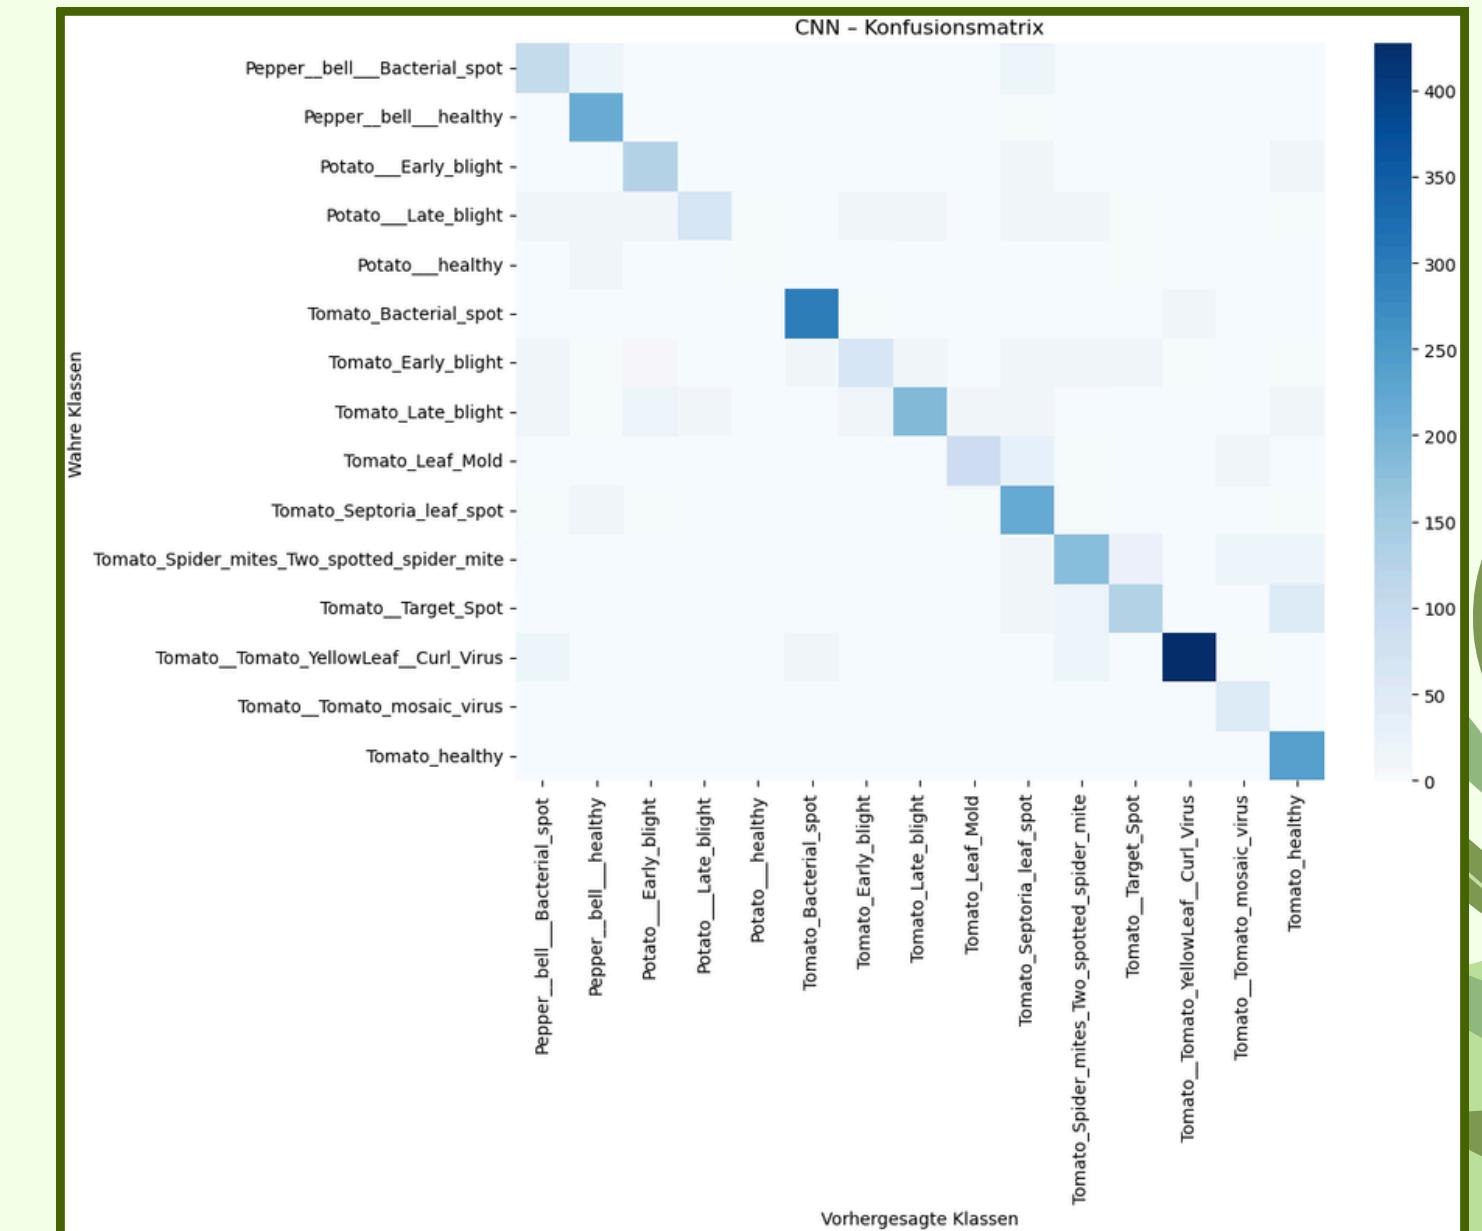
# CNN PLOTS



# CNN CLASSIFICATION REPORT + KONFUSIONSMATRIX

	precision	recall	f1-score	support
Pepper_bell_Bacterial_spot	0.62	0.70	0.66	149
Pepper_bell_healthy	0.76	0.97	0.85	221
Potato_Early_blight	0.75	0.84	0.79	150
Potato_Late_blight	0.87	0.45	0.60	150
Potato_healthy	0.40	0.17	0.24	23
Tomato_Bacterial_spot	0.93	0.93	0.93	319
Tomato_Early_blight	0.69	0.44	0.54	150
Tomato_Late_blight	0.87	0.66	0.75	287
Tomato_Leaf_Mold	0.86	0.62	0.72	143
Tomato_Septoria_leaf_spot	0.66	0.82	0.73	266
Tomato_Spider_mites_Two_spotted_spider_mite	0.72	0.72	0.72	252
Tomato_Target_Spot	0.69	0.61	0.65	210
Tomato_Tomato_YellowLeaf_Curl_Virus	0.96	0.89	0.92	482
Tomato_Tomato_mosaic_virus	0.56	0.98	0.71	56
Tomato_healthy	0.69	1.00	0.82	238
accuracy			0.78	3096
macro avg	0.73	0.72	0.71	3096
weighted avg	0.79	0.78	0.77	3096

- Fehler entstehen bei visuell ähnlichen Krankheiten
- kleine Klassen sind auch Probleme



# TRANSFER LEARNING: IDEE

- Vortrainierte Modelle (ImageNet)
- Nutzung gelernter visueller Features
- Nur Klassifikationskopf trainiert (trainable = False)

## Modelle:

- EfficientNetB0
- MobileNetV2
- ResNet50V2

## für fairen Vergleich:

- gleiche Daten
- gleicher Trainingsaufbau

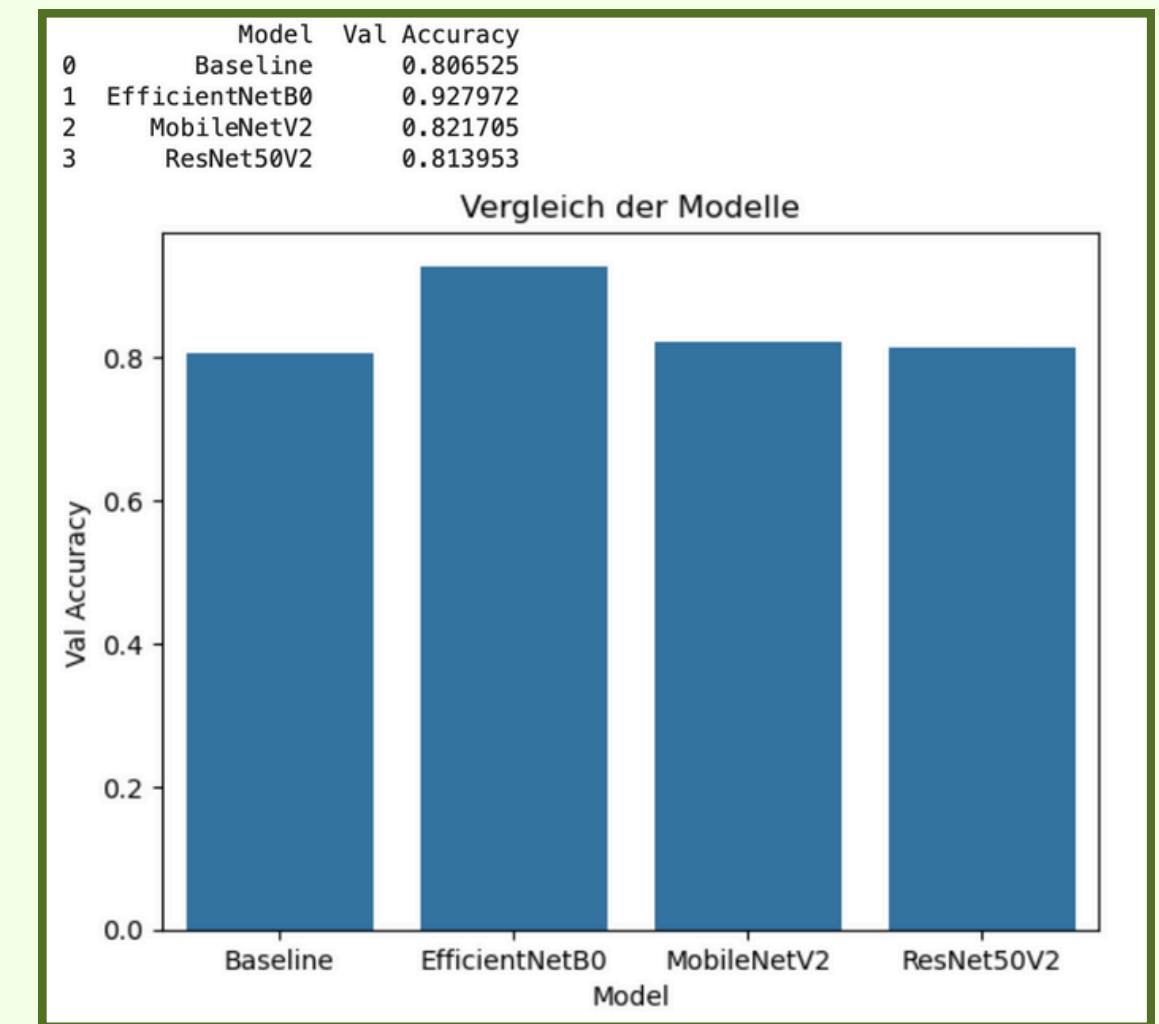
# TRANSFER LEARNING: MODELLVERGLEICH

## alle Modelle:

- gleiche Daten
- gleicher Split
- gleicher Trainingsablauf



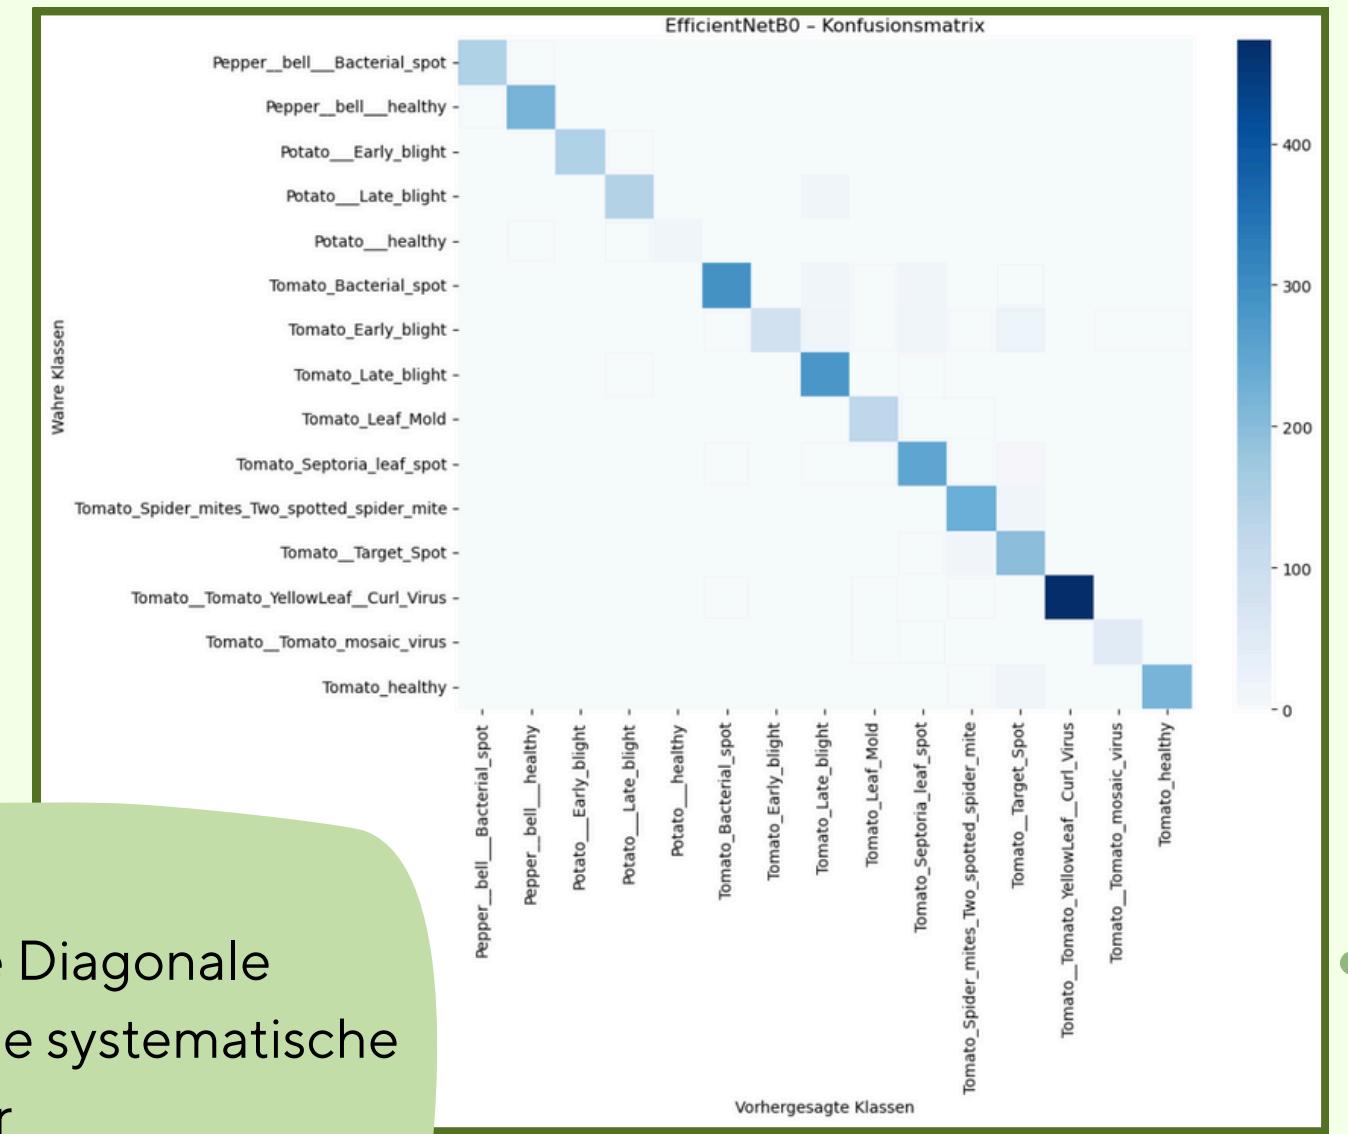
EfficientNet deutlich besser



# EFFICIENTNET - KONFUSIONSMATRIX

- Hohe Trefferquote pro Klasse
- Fehler vor allem zwischen ähnlichen Krankheiten
- Kaum Verwechslung „gesund ↔ krank“

- starke Diagonale
- wenige systematische Fehler



# TRANSFER LEARNING: EINORDNUNG

Warum funktioniert TL hier gut?

- Vortrainierte Textur- & Kantenmerkmale
- Pflanzenkrankheiten = visuelle Muster
- Wenig Training nötig (Freeze)

Aber:

- Datensatz unter idealen Bedingungen
- eingeschränkte Übertragbarkeit auf Outdoor-Bilder

# EXPLAINABLE AI

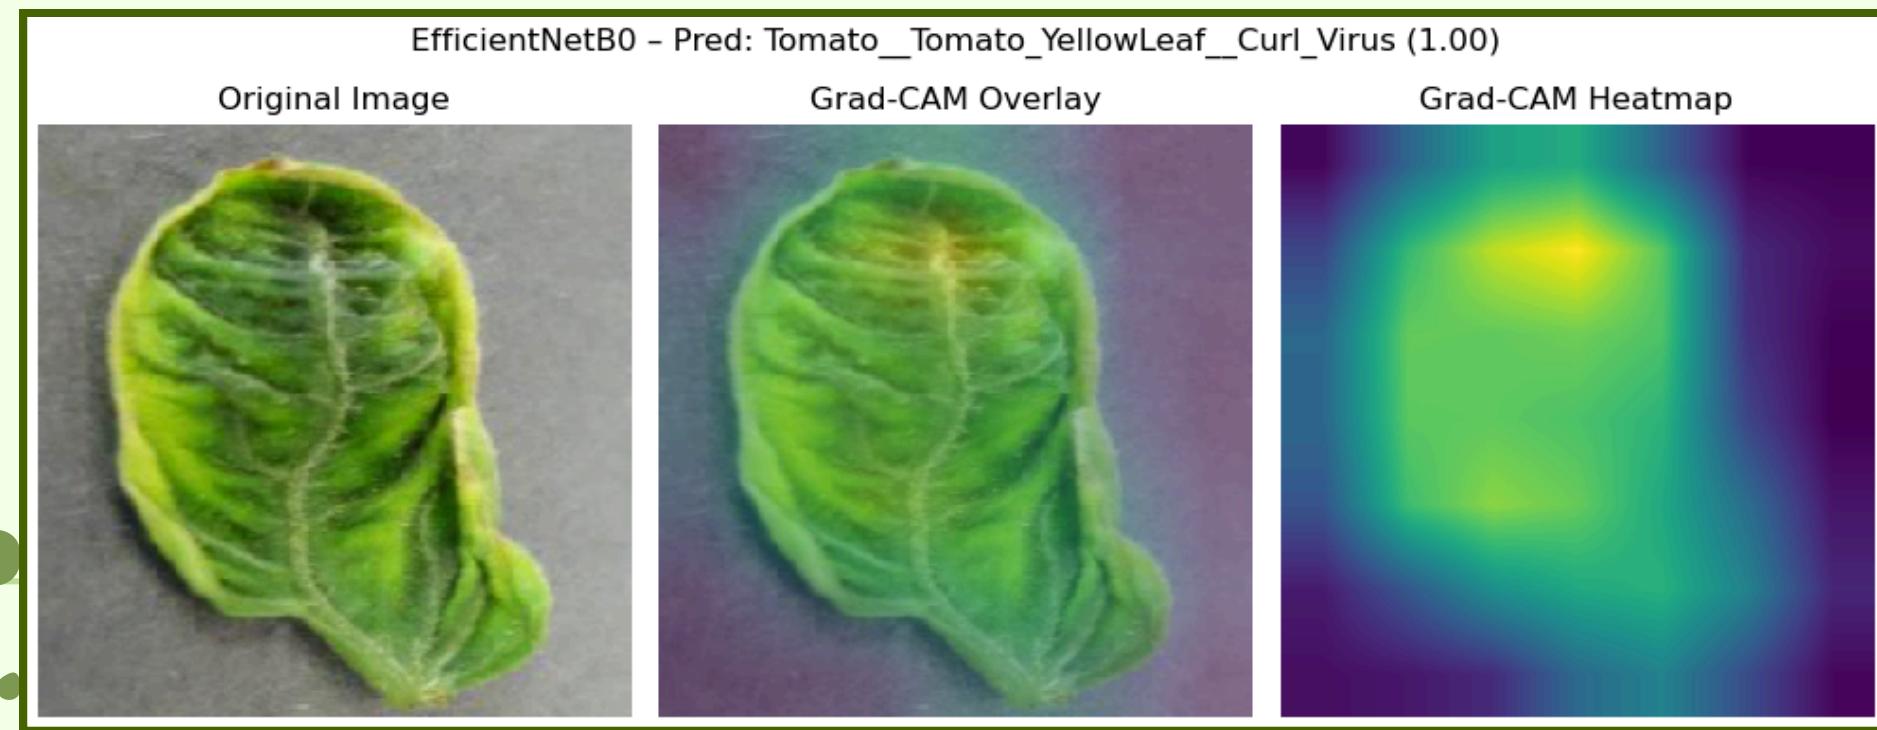
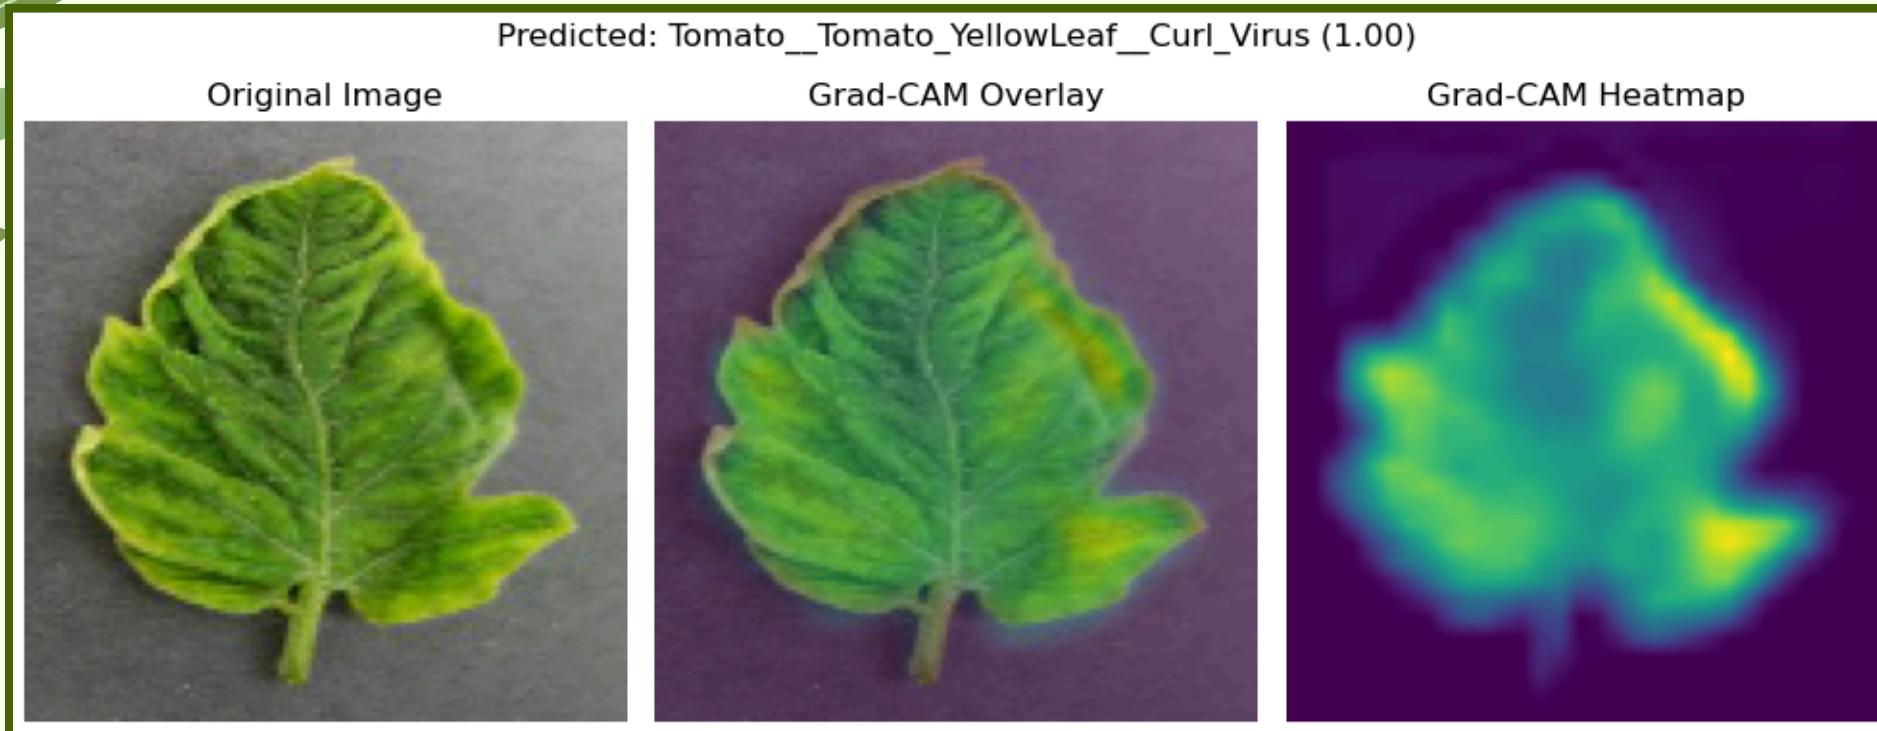
Explainable AI hilft dabei:

- die Entscheidungen der Neuronalen Netze nachzuvollziehen
- Grad-CAM visualisiert relevante Bildbereiche für eine Vorhersage

Aber:

- Auflösung der Heatmaps ist nur grob, feine Details gehen verloren
- Abhängig vom letzten Conv-Layer

# EXPLAINABLE AI CNN VS EFFICIENTNET



- beide Modelle erkennen dieselbe Krankheit korrekt
- ähnliche Fokusbereiche
- genaue Hotspots unterscheiden sich leicht

Q  
8

A

**Danke für eure  
Aufmerksamkeit :)**